

VessShape: Rascunho de metodologia e descrição do dataset

Wesley Nogueira Galvão¹ and Cesar H. Comin^{1,*}

¹*Department of Computer Science, Federal University of São Carlos, São Carlos, SP, Brazil*

(Dated: September 9, 2025)

Este documento reúne rascunhos de texto e fórmulas para a subseção metodológica do dataset VessShape, mantendo o mesmo template do artigo principal.

I. METODOLOGIA

A. VessShape — Composição sintética com viés de forma

O VessShape é um conjunto sintético que combina formas tubulares semelhantes a vasos sanguíneos com texturas variadas de primeiro plano e de fundo. A ideia central é manter a geometria estável enquanto se muda drasticamente a textura, forçando modelos a aprenderem pistas de *forma* (conectividade, afilamento, bifurcações) em vez de dependerem de textura.

Geometria por curvas Bézier. Cada ramo vascular C_k é descrito por uma curva de Bézier de ordem n com pontos de controle $\{\mathbf{P}_{k,i}\}_{i=0}^n$:

$$\mathbf{c}_k(t) = \sum_{i=0}^n \binom{n}{i} (1-t)^{n-i} t^i \mathbf{P}_{k,i}, \quad t \in [0, 1]. \quad (1)$$

Os pontos de controle são amostrados de forma a produzir ramos conectados (compartilhando extremos) e ângulos de bifurcação plausíveis; a tortuosidade é ajustada por pequenas perturbações nos pontos de controle. Usamos faixas simples e reproduzíveis: número de curvas K amostrado em $[1, 20]$; número de pontos de controle por curva em $[2, 20]$ (controla a complexidade da Bézier); e uma escala de deslocamento típica dos pontos de controle em pixels $\delta \in [50.0, 150.0]$, que regula a curvatura/tortuosidade.

Na rasterização, adotamos espessura constante r_0 por ramo (coerente com o uso de `binary_dilation` no código). Em termos contínuos, a máscara pode ser descrita como

$$M(x) = \mathbb{K} \left(\min_k \inf_{t \in [0,1]} \|x - \mathbf{c}_k(t)\| \leq r_0 \right), \quad x \in \Omega, \quad (2)$$

e, no domínio discreto, corresponde a desenhar a polilinha de \mathbf{c}_k (`skimage.draw.line`) seguida de `binary_dilation(img, iterations=radius)`. Um fechamento morfológico opcional remove pequenas lacunas.

Composição de texturas. Para cada amostra selecionamos uma textura de primeiro plano F (aplicada nas regiões dos vasos) e uma de fundo B (categorias distintas, e.g., do ImageNet). Antes da composição, executamos um *crop* aleatório em cada textura para o tamanho-alvo

$H \times W$ (ex.: 256×256), garantindo dimensões consistentes com a máscara M . A transição é suavizada por um *alpha matte* A obtido ao desfocar M com `gaussian filter` e normalizar A para $[0, 1]$ (dividindo pelo máximo). A imagem final é dada por

$$I(x) = A(x) F(x) + (1 - A(x)) B(x), \quad x \in \Omega. \quad (3)$$

Usamos um desfoque Gaussiano com desvio-padrão σ ($A = G_\sigma * M$). Para integração no treinamento supervisionado, normalizamos I por canal usando estatísticas típicas do ImageNet (médias e desvios por canal), mantendo compatibilidade com práticas comuns em redes de visão. Para consistência, quaisquer transformações geométricas (rotação, escala, estiramento suave) são aplicadas de forma idêntica à imagem I e à máscara M .

Parâmetros e amostragem aleatória. Trabalhamos com imagens quadradas de tamanho 256×256 . Em cada amostra:

Relação com o código (nomes das variáveis). Para rastreabilidade entre a descrição acima e a implementação:

- $K \leftrightarrow \text{num_curves}$
- $n+1$ (total de pontos de controle) $\leftrightarrow \text{n_control_points}$ (grau $n = (n+1) - 1$)
- $\delta \leftrightarrow \text{max_vd}$ (escala de deslocamento dos pontos de controle)
- $r_0 \leftrightarrow \text{radius}$ (iterações da `binary_dilation`)
- $\sigma \leftrightarrow \text{sigma}$ (desfoque Gaussiano do *alpha* A)
- $H \times W \leftrightarrow \text{image_size}$ (após *random crop*)
- *margem* $\leftrightarrow \text{extra_space}$ (amostragem geométrica antes do *crop*)
- precisão da curva $\leftrightarrow \text{precision}$ (pontos por curva para rasterização)
- restrição de extremos $\leftrightarrow \text{min_dist/max_dist}$ (distância mínima/máxima entre extremos)

Saídas e propósito. Cada amostra produz o par (I, M) : imagem composta e sua máscara de segmentação correspondente. Ao trocar amplamente as texturas de F e B e manter a geometria induzida por M , seguimos o princípio de [?] para estimular um viés de forma benéfico ao treinamento de segmentadores de vasos.

* Corresponding author: comin@ufscar.br

TABLE I. Parâmetros de geração do VessShape, faixas de amostragem e descrição.

Parâmetro	Faixa	Descrição
Número de curvas K	[1, 20]	Quantidade de ramos/vasos gerados por amostra.
Pontos de controle $n+1$	[2, 20]	Complexidade da curva de Bézier (ordem n).
Escala de deslocamento δ (px)	[50.0, 150.0]	Controla curvatura/tortuosidade via amplitude típica do deslocamento dos pontos de controle.
Raio r_0 (px)	[1, 5]	Espessura constante dos vasos, obtida por dilatação morfológica da polilinha rasterizada.
Desfoque do matting σ	[1, 2]	Desvio-padrão do Gaussiano usado para $A = G_\sigma * M$.

Algorithm 1 Geração de uma amostra VessShape (visão geral)

```

1: Amostrar  $K$ ,  $n+1$ ,  $\delta$ ,  $r_0$ ,  $\sigma$  e demais hiperparâmetros
2: for  $k \leftarrow 1$   $K$  do
3:   Amostrar  $\{\mathbf{P}_{k,i}\}$  e construir  $\mathbf{c}_k$  (curva de Bézier)
4:   Rasterizar polilinha de  $\mathbf{c}_k$  e dilatar com raio  $r_0$  (ob-
     tendo contribuição em  $M$ )
5: end for
6: Selecionar texturas  $F$  e  $B$ ; aplicar random crop para  $H \times W$ 
7:  $A \leftarrow \text{normalize}(G_\sigma * M)$ 
8:  $I \leftarrow A \odot F + (1 - A) \odot B$  (Eq. ??)
9: Aplicar aumentos coerentes em  $I$  e  $M$ ; retornar  $(I, M)$ 

```

AGRADECIMENTOS

C. H. Comin agradece à FAPESP (processo 21/12354-8) pelo apoio financeiro.
